




ANÁLISIS EXPLORATORIO DE DATOS

DEL MERCADO DE VEHÍCULOS USADOS



Introducción y objetivo del análisis

El informe ejecutivo consta de un análisis, preparación y entrenamiento de un modelo de machine learning a través de la comparación de distintos modelos de regresión. Para realizar la tarea hemos obtenido un conjunto de datos de <https://www.kaggle.com/competitions/playground-series-s4e9/data> con el objetivo de predecir los posibles precios de los coches en la actualidad.

Para ello se realizará un análisis sobre las diferentes columnas para ver como afectan a la variabilidad del precio del vehículo. Esto incluye variables como:

- Marca
- Modelo
- Año de entrada al mercado del vehículo
- Tipo de combustible que utiliza
- El motor que utiliza
- Transmisión
- Color tanto interior como exterior
- Si el vehículo ha tenido accidentes
- Papeles en regla
- Precio del vehículo.


Proceso de limpieza

El proceso de limpieza del dataset que hemos seguido es el siguiente.

1. Obtenemos la fuente de datos que hemos descargado del enlace anteriormente mostrado. Al ser dos archivos .csv distintos lo concatenamos para unificarlos.
2. Analizamos los datos mostrados y vemos el conjunto de valores nulos que tenemos.
 - a. El primer paso tomado aquí es el de eliminar los vehículos cuyo año de salida sea 1974. Decidimos eliminar estos datos debido a que no siguen la continuidad de nuestros datos y no representan ni un 1% de los datos.
 - b. Analizando el campo 'clean_title', que se enfoca en los papeles del vehículo, vimos que tenía muchos valores nulos. Llegamos a la conclusión de que los valores nulos deben ser remplazados por el valor "No", ya que la columna solo registraba los valores "Yes".
 - c. Eliminamos el campo 'id', ya que solo estaba para una parte de los datos muy pequeña y no eran de utilidad
 - d. Decidimos realizar one-hot encoding para los tipos de combustibles. Primero normalizamos los datos, en segundo lugar mapeamos los datos y lo reducimos a 4 posibles valores (Diesel, Gasoline, Electric e Hybrid).

- e. El campo 'accident' solo tiene dos valores posibles (None reported y At least 1 accident), por lo que los valores nulos los reemplazamos por el valor None reported.
- f. Para el campo 'brand' utilizamos one-hot encoding, aunque tomamos la decisión de asignarle un "id" a cada marca en una sola columna.
- g. Eliminamos los valores nulos que queden restantes y que no tengan utilidad.
- h. Normalizamos los campos 'transmission', 'int_col' y 'ext_col' reduciendo el número de valores posibles. Además de normalizar los campos 'milage' y 'price' para poder cambiar los tipos de datos correctamente.
- i. Dividimos el campo engine en varios campos distintos: 'engine_liters', 'cylinders', 'turbo' y 'horsepower'.
- j. Eliminamos los vehículos cuyo precio sea mayor a 1 millón de euros ya que representan unos outliers muy grandes y no representan mucho dentro del conjunto de datos.

Matriz de correlación de variables



El precio del vehículo se ve muy influenciado principalmente por el año del modelo y el kilometraje.

- Siendo directamente proporcional el precio con el año del modelo, lo cual tiene sentido ya que cuanto más reciente sea el vehículo mayor será el precio.
- Sin embargo el kilometraje es inversamente proporcional, ya que cuanto mayor sea los kilómetros del coche menor será el precio, ya que significa que el coche ha sido más usado.
- También vemos como el hecho de que tenga accidentes o no tiene un impacto sobre el precio también.

Las variables acerca del motor del vehículo también tienen una correlación relevante.

- Cilindrada, cilindros y potencia crecen conjuntamente, ya que influyen en la potencia que tiene el vehículo, además cuanto mayor sea la potencia del motor

más probabilidad tiene de que el vehículo tenga turbo incorporado. Esto está afectando también al precio del vehículo.


- Otro campo relacionado con el motor son los caballos del vehículo que puede parecer que tiene un impacto muy débil, pero la realidad es que la variable cuenta principalmente el impacto que tiene aumentar un caballo al vehículo pero si nos vamos a los valores reales que pueden presentar los coches, vemos que si tienen un impacto mayor.
- Existe una pequeña correlación también entre el tipo de combustible utilizado y el precio del vehículo, siendo el que mayor impacto tiene el eléctrico, debido a que es el más novedoso y los que más se está intentando implementar a día de hoy, seguido de los híbridos y los de gasolina que tiene un impacto un poco inferior sin llegar a ser algo significativo.

Bloque 1 — Estructura del precio: antigüedad y uso

El precio “base” de un coche usado se construye sobre un conjunto de variables analizadas anteriormente, que son principalmente:

- año del modelo (antigüedad)
- kilometraje (uso)
- Variables de potencia de motor
- Tipo de combustible
- Coche accidentado

Figura 1. Precio de los coches según año del modelo (detección de outliers).



El método utilizado para la detección de outliers es IQR, para su posterior visualización en un scatterplot. Para ello hemos definido los límites superiores e inferiores para tratar los outliers correctamente.

De esta forma vemos como pese a haber lo que parecen una cantidad de outliers muy grande tenemos que tener en cuenta que nuestro conjunto de datos cuenta con ~193mil datos por lo que la mayoría de ellos se mantienen dentro de los rangos establecidos. Además, la gran cantidad de outliers se encuentran en un rango cercano al límite superior.

Figura 2. *Análisis descriptivo de los datos (Media, moda y distribución de los precios).*

De esta forma hemos conseguido reducir el ruido y la desviación de las medias de nuestros datos, siendo la siguiente:

- Media del precio: 42,222.13
- Mediana del precio: 30,786.50
- Moda del precio: 15000.00

Y siendo la distribución de los datos de precio la siguiente:





Figura 3. *Evolución del precio medio según año del modelo (barras) y número de coches por año (etiquetas), con línea de tendencia.*




Observamos una tendencia alcista de las medias a lo largo de los años.

- Aumento sostenido del precio medio en los años recientes (2015–2024), siendo el pico en el año 2023 coincidiendo con el número de vehículos disponible. Uno de los motivos que vemos es que no es por cantidad de coches sino por mejoras tecnológicas.
- Precios más bajos y menor volumen en vehículos antiguos (1992–2000), indicando que la mayoría de vehículos más antiguos tienen menor valor en el mercado.
- Relación entre volumen de datos y estabilidad del precio medio, en los años con mayor cantidad de vehículos el precio muestra una tendencia más estable.

Bloque 2 — Composición del mercado

¿Qué tipo de coches dominan el dataset y cómo afecta eso a la lectura del precio?

Figura 4. Distribución de marcas en el conjunto de datos



Este gráfico nos indica que marcas de coche tiene mayor peso dentro del conjunto de datos.

- Vemos que hay una marca clara que ocupa un gran porcentaje en los datos que es la marca Ford, siendo unos ~30mil coches aproximadamente exclusivas de esta marca.
- Seguidos relativamente de cerca de Mercedes-Benz, BMW, y Chevrolet, cuyos valores están entre 15 y 20 mil registros de estos vehículos.

A continuación, se muestra un gráfico del porcentaje que representan las top 10 marcas

Figura 5. *Proporción de marcas en el conjunto de datos*





Figura 6. Precio medio en el Top-10 de marcas más representadas



Vemos que al igual que el porcentaje de marcas representadas en el dataset, el top 10 precio medio por marcas coincide perfectamente, aunque cambiando el orden.


En el primer lugar encontramos Porsche que es una marca de vehículos de alta gama, a esto le sigue Land, Mercedes-Benz y BMW que son al igual que Porsche vehículos generalmente caros.

Además al ser los más representados tienden a mostrar datos más fiables al poder comparar con mayor cantidad de registros.

Bloque 3 — Tipo de combustible

¿Qué combustible tiene mayor influencia en el mercado?

Figura 7. *Precio medio por tipo de combustible.*




Como podemos ver en la gráfica hay una clara subida de precio medio en los coches eléctricos e híbridos, debido al material y las tecnologías empleadas en este tipo de vehículos.

Aunque esto pueda indicar que los coches eléctricos son los mas caros no necesariamente tiene porque ser exactamente así, debido a la representación de los tipos de combustible en el dataset completo, como podemos ver en la siguiente gráfica.

Figura 8. *Distribución porcentual por tipo de combustible.*

Distribución porcentual por tipo de combustible



Como vemos la mayoría de coches que se encuentran utilizan como combustible la gasolina, esto nos indica que representarán la mayor cantidad de datos tanto por la parte superior como la inferior de los precios, además de contar con más registros en la parte central de los precios haciendo que tenga una media más estable que el resto.

Esto lo podemos ver representado en la siguiente gráfica donde vemos como se distribuyen los precios

Figura 9. *Distribución de precios por tipo de combustible.*






Figura 10. Top 10 marcas coches eléctricos.



Como ya hemos mencionado anteriormente no hay muchos coches que sean eléctricos, y la mayoría de marcas son relativamente recientes en el mercado.

La principal es tesla, cuyos coches suelen ser más caros que la media, aunque se pueden observar coches que no son caros que se puede deber a otras variables como accidentes reportados, kilometraje, etc.

Figura 11. Relación entre precio y kilometraje con regresión polinómica.



La gráfica permite visualizar la tendencia general de depreciación del precio conforme aumenta el kilometraje, al mismo tiempo que evidencia una gran variabilidad de precios y las limitaciones de un modelo simple para explicar el comportamiento del mercado.

Por último Podemos ver un comportamiento extraño al final de la curva, tomando una tendencia a la alza, lo que nos indica que hay vehículos que a pesar del alto kilometraje, esto puede deberse a los pocos datos que tenemos en esa zona en concreto o presencia de valores atípicos.

Conclusión final

En conclusión, el análisis exploratorio realizado permite comprender de forma clara la estructura del precio de los vehículos en el mercado actual y los factores que más influyen en su variabilidad. Los resultados muestran que la antigüedad del vehículo y el kilometraje son las variables más determinantes en la formación del precio, siguiendo patrones coherentes de depreciación con el uso y revalorización en modelos más recientes. A esto se suman características técnicas del motor —como potencia, cilindrada y presencia de turbo— y factores contextuales como el historial de accidentes, que refuerzan o penalizan el valor final del coche.

Asimismo, el estudio evidencia cómo la composición del mercado condiciona la interpretación de los precios: marcas con mayor representación aportan mayor estabilidad estadística, mientras que marcas de alta gama concentran precios medios más elevados. En cuanto al tipo de combustible, se observa una clara prima de precio en los vehículos eléctricos e híbridos, reflejo de su innovación tecnológica y su posicionamiento actual en el mercado, aunque su menor representación limita la generalización directa de estos resultados.

En conjunto, la limpieza, transformación y análisis de los datos han permitido reducir ruido, detectar outliers relevantes y extraer patrones significativos que sientan una base sólida para el posterior entrenamiento y comparación de modelos de regresión. Este trabajo no solo facilita una mejor comprensión del comportamiento del mercado de vehículos usados, sino que también garantiza que los modelos de machine learning contruidos a partir de este dataset partan de datos coherentes, representativos y alineados con la realidad del mercado.